Beyond Illusory Energy Savings in O-RAN: Diagnosing Reward Hacking and Enforcing QoS via Constrained Offline RL

Auditoria Empírica em ns-3, Redução Algébrica de Estado e Formulação CMDP (alvo: IEEE Transactions / Flagship)

Eliothluy
eliothluy@gmail.com

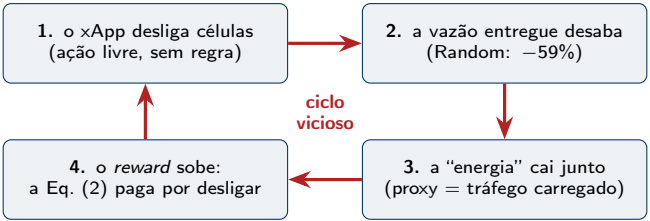
LaCIS – ITEC – Universidade Federal do Pará (UFPA)

28 de outubro de 2026

Em uma frase: provamos, com 40 runs reais de ns-3, que o estado da arte confunde *desligar células* com *poupar energia* — e propomos o primeiro benchmark QoS-aware com Offline RL restrito para operar na região que

O Problema — "eficiência" que vem de parar de entregar tráfego

Analogia: fechar a loja economiza a conta de luz — mas isso não é eficiência. **Eficiência é vender o mesmo com menos luz.** A literatura recente de *energy saving* em O-RAN — incluindo Bordin et al. (CCNC 2025) — não separa as duas coisas.



No artigo base: $\gamma = EC \cdot P_{tx}$ é uma **contagem de transport blocks** (P_{tx}=1) e a QoS (vazão, RLF) aparece apenas na *avaliação* — **nunca no treino**.

A Descoberta em 3 Passos (o *smoking gun*, ns-3 real)

1. O reward paga por desligar

$$-0{,}953$$

$$\mathrm{corr}(R,\ B_{sON})$$

B_{sON} = n.° de células ligadas: é **estado**, não desempenho — e carrega **40%** de toda a massa negativa do reward (era **89,7%** antes de calibrar).

2. O ótimo é a pior política

$$5\ /\ 6$$

conjuntos de pesos da Tabela I em que a **Random** vence

reward médio: Random $-0{,}238$ vs. Always-On $-0{,}466$ — com -59% de vazão e RLF máximo de 48 UEs.

3. "Economia" = tráfego não entregue

$$1{,}979\times$$

energia por bit da Random vs. Always-On

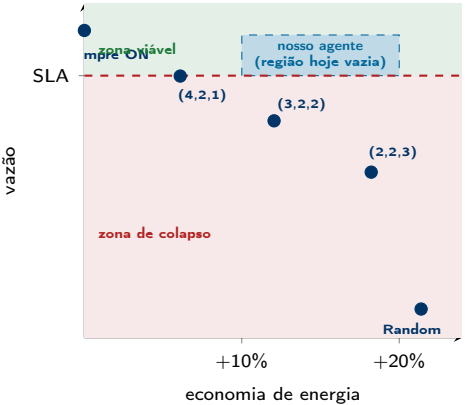
$1{,}000 \rightarrow 1{,}093 \rightarrow 1{,}148 \rightarrow 1{,}979$: piora em **100% dos baselines**. Sempre $|\Delta\mathrm{Thr}| > |\Delta E|$.

Conclusão do diagnóstico: **recalibrar pesos não resolve** — a falha é *estrutural* (w_2 duplicado; QoS fora do treino). O problema precisa ser reformulado, não re-ponderado.

Nossa Proposta em 1 Figura — economizar *sem quebrar o serviço*

1. **Medir energia de verdade**
   modelo EARTH em watts: $P_{\text{on}} = 130 + 94x$ W,
   $P_{\text{sleep}} = 75$ W (decisão D1)
2. **Proibir o colapso *no treino* (CMDP)**
   o prêmio de energia só é pago com o SLA cumprido:
   vazão $\geq \tau_{\text{SLA}}$, RLF $\leq \kappa$ (E1)
3. **Aprender *offline* de verdade**
   IQL/CQL discreto no lugar do "PPO" que ignora a própria ação (D4) + estado **compact70** via SVD

A pergunta que o artigo responde: *quanto dá para economizar sem quebrar o serviço?* — hoje sem resposta, porque o benchmark existente nem faz a pergunta.



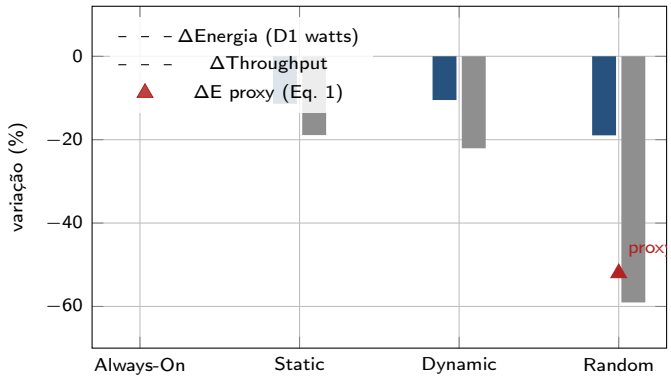
Alvo pré-registrado: $\Delta E \in [10, 20]\%$ com $\Delta\text{Thr} \geq -10\%$ e RLF ≤ 2, IC95 sobre 5 seeds.

Auditoria Metodológica — Artigo Base vs. Nossa Implementação

Eixo crítico	Artigo base (CCNC 2025)	Nossa implementação auditada
Modelo de energia	$\gamma_i = EC_i \cdot P_{tx}$ = contagem de TB (proxy), P_{tx}=1	**D1: EARTH macro em W**: $P_{\mathbf{on}} = 130 + 94x$ W, $P_{\mathbf{sleep}} = 75$ W; teto físico de poupança 33,5–66,5%/célula
Normalização	população não declarada; *fallback* comprime componentes ($bs_{on} = 89{,}7\%$ da massa negativa)	**D3: quantílica por célula**, calibrada em runs reais (`reward_calibration_d1d3.npz`)
Algoritmo "offline"	"PPO offline" via replay que *ignora a ação* do agente $\Rightarrow$ behavior cloning ponderado	**D4: IQL discreto** (`iql.py`); CQL no DQN; replay mantido só como ablação
Estado	"85 KPMs" com duplicatas: r=1,0; rank($X_{\mathbf{85}}$) = 70	**Compact70** via SVD (posto completo; `STATE_VARIANTS["compact70"]`)
Restrição de QoS	RLF/vazão apenas na *avaliação* (Tabela VI)	**CMDP no treino**: Lagrangiano (grade λ) + porta de SLA; *87 testes aprovados*

`implementation-audit.md` (27 confirmados / 12 parciais / 4 ausentes / 6 divergentes) · `experiment-configs/decisions.md` (D1-D5)

Fig. 1 — A Ilusão da Economia de Energia (21 runs, modelo D1 em watts)



Barras: 21 runs oficiais (IC95 no `baseline_summary.csv`); triângulo: proxy do artigo exagera a "economia" da Random em ≈2,7×.

Intensidade energética E/thr (Always-On = 1)

Always-On	1.000
Static	1.093
Dynamic	1.148
Random	**1.979**

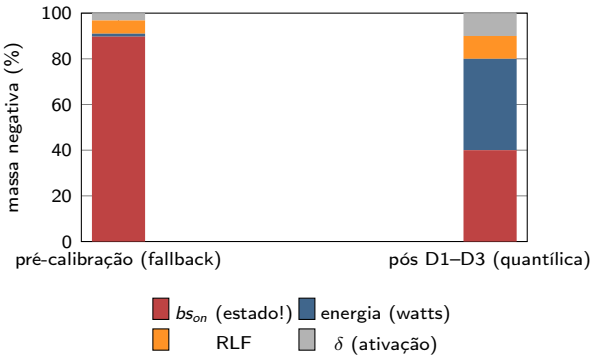
Leitura

Toda política gasta **mais watts por bit entregue**; a poupança absoluta vem de transportar **menos tráfego** (ΔE sempre menor que ΔThr).

Fig. 2 — Anatomia Matemática do *Reward Hacking* na Eq. (2)

$$r = w_1\rho - w_2\gamma - w_3\varsigma - w_4\delta - w_2 B_{sON}$$

w_2 aparece 2× ⇒ eixo energético efetivo $= 2w_2$; B_{sON} é **estado**, não desempenho.



Sensibilidade aos 6 pesos da Tabela I (reward médio)

Agente	Always-On	Static	**Random**
PPO-1 (w_2=0.19)	−0.121	−0.076	−0.086
PPO-2 / DQN	−0.466	−0.273	−0.238
PPO-3	−0.693	−0.472	−0.410
PPO-4	−0.379	−0.241	−0.214
PPO-5	−0.196	−0.142	−0.138

Correlações medidas (2.079 transições reais)

$\mathrm{corr}(R,\, B_{sON}) = -0.953$ $\quad$ $\mathrm{corr}(R,\, \rho) = -0.527$

⇒ o reward **premia desligar células**, não poupar energia por bit.

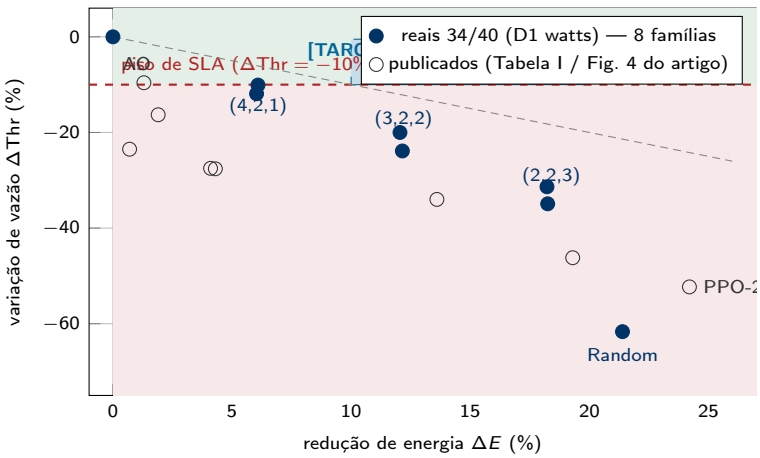
Resultados Empíricos por Tupla — Campanha Tier S (34/40 runs)

Tupla (células OFF)	**Família**	**Runs**	ΔE **(%)**	ΔThr **(%)**	**RLF máx**	E/**thr**
— (7 ON)	Always-On	5/5	+0,00	0,00	18	1.000
4-2-0-1 (1 OFF)	Static	3/5	+6,09	−10,09	18	1.044
	Dynamic	4/5	+6,03	−11,90	18	1.049
3-2-0-2 (2 OFF)	Static	5/5	+12,05	−20,00	20	1.087
	Dynamic	5/5	+12,15	−23,87	22	1.094
2-2-0-3 (3 OFF)	Static	4/5	+18,22	−31,36	26	1.141
	Dynamic	3/5	+18,25	−34,92	27	1.148
aleatório (3,5 ON méd.)	**Random**	5/5	+21,39	−61,66	**48**	**1.979**

Variância entre seeds: energia é *determinística* ($\mathrm{dp} \leq 0{,}19$ pp — depende só das horas de sleep), mas vazão espalha **9,98–18,90 pp** entre seeds (o próprio Always-On: $\pm 20{,}7\%$). $\Rightarrow$ avaliações *single-seed* são estatisticamente inválidas; tudo nosso reporta 5 seeds.

`pareto_families_d1.json / pareto_perseed_d1.json · runs excluídos: os 6 crashes do slide 8`

Fig. 3 — Quanto dá para economizar sem quebrar o SLA? (Fronteira de Pareto)



Zona de colapso (vermelha)

Random, PPO-2, PPO-4, PPO-5 e as tuplas (3,2,2)/(2,2,3): "economia" ⇔ vazão desabada.

Zona viável (verde)

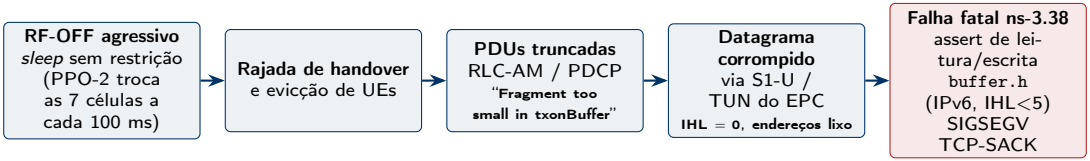
Hoje só nas tuplas (4,2,1) — que economizam pouco (+6%). A região alta ($\Delta E \in [10, 20]\%$) está **vazia**: 1 pp de energia custa **1,6–2,9 pp** de vazão em *todos* os pontos conhecidos.

⇒ PNG do Pareto ainda não gerado

Frente 1 — Achado Transversal: Instabilidade da Pilha de Protocolos

6/40 runs quebraram — 100% nas políticas com células em *sleep*

Always-On e Random completaram **5/5 seeds**; os 6 crashes concentram-se nas tuplas (2,2,3) e (4,2,1) de Static/Dynamic (3 × `NS_ASSERT` de buffer + 3 × `SIGSEGV`), em $t = 1{,}1$ / 7,64 / 9,9 s — causa confirmada por *coredumps* do systemd e reprodução determinística sob GDB.



Engenharia + tese para o paper

Patch aplicado e compilando (`./ns3 build` → exit 0): `ipv4-header.cc:444-448` rejeita `ihl<5` em `Deserialize()` + `GetSerializedSize()` ≥ 20 B (descarte com aviso, como PDCP/SACK/IPv6). **Tese:** *o espaço de ações irrestrito não é operacionalmente viável — xApps reais exigem garantias de segurança (mínimo de células ativas, histerese) que δ_i na Eq. (2) só parcialmente captura.*

Frente 2 — CMDP: a Ideia em Uma Frase

"O bônus de energia só é pago quando o serviço está cumprido — como o bônus de um vendedor, atrelado à nota de satisfação do cliente."

$$r' \;=\; r \;-\; \lambda \cdot \underbrace{\max\!\big(0,\; \tau_{\mathrm{SLA}} - \bar{\rho}^{(W)}\big)}_{\text{quanto o SLA está sendo violado na última janela}}$$

- λ é o "tamanho da multa": a grade fixa $\lambda \in \{0;\ 0{,}5;\ 1;\ 2;\ 5;\ 10\}$ gera **um ponto na fronteira de Pareto por valor** — do sem-restrição ao conservador.
- **Via alternativa (porta suave, Eq. 5.1′):** em vez de multar, *desliga o prêmio* — os termos de energia (w_2) só entram no reward quando o SLA passa.

Ambas implementadas e testadas: **87 testes aprovados**; detalhes e a auditoria adversarial no próximo slide.

Frente 2 (detalhes) — Grade Lagrangiana e Porta Suave Auditadas (Rev. 1)

Por que o dual primal–dual ingênuo diverge *offline*

Custo hinge médio do dataset:
$\bar{c}_{\mathcal{D}} = 0{,}0757 > \delta = 0{,}05 \Rightarrow$ deriva dual $+2{,}57 \times 10^{-4}$/passo; $\lambda \approx 12{,}9$ em 50k passos e **satura** $\lambda_{\max}$=100 **em** ≈388**k** (dentro do orçamento de 1,2M). Em λ=12,9: penalidade λc até 9,1 $\gg |r| \approx 0{,}1$–$0{,}5$. Com dataset fixo, a média de lote é a constante do comportamento — o dual não persegue ponto de sela.

Ajustes blindados A1–A5 (parecer adversarial incorporado)

A1: regra de coerência $\delta \times \bar{c}_{\mathcal{D}}$ pré-treino; A2: crítico de custo $V_c(s) + \hat{J}_c$ sob a política corrente (FQE/MC, Robbins–Monro com teto); A5: correção de [illegible] PPO-SB3

Via 1 — Grade Lagrangiana *offline* (A3–A4)

$$r_\lambda = r - \lambda \max\left(0,\ \tau_{\text{SLA}} - \bar{\rho}^{(W)}\right)$$

Grade fixa $\lambda \in \{0; 0{,}5; 1; 2; 5; 10\}$, $\lambda_{\max} = 10$, guarda $\lambda\bar{c}/|\bar{r}| \leq 5$. **Cada λ = um ponto candidato na fronteira de Pareto** (treino offline é barato; caro é o live).

Via 2 — Porta suave de SLA, Eq. (5.1′)

$$r' = w_1\rho - w_3\varsigma - w_4\delta - g_\tau\left(\bar{\rho}^{(W)}\right) \cdot \left(w_2\hat{\gamma} + w_2\hat{B}_{sON}\right)$$

Ambos os canais de w_2 entram *dentro* do gate: fora dele, a política deixa de ser paga por desligar BS violando o SLA. Porta suave = padrão (porta dura esparsa em 25–34% das indicações, W=10). Estado aumentado com a janela $\bar{\rho}^{(W)}$ (markovianidade): `full+gate` 86 / `compact+gate` 79 / `compact70+gate`

Frente 4 — Auditoria Algébrica de Estado: 85 → 70 KPMs via SVD

15 dims removidas	Índices	Redundância e
7× `mac_pdu_64qam`	9, 21, 33, 45, 57, 69, 81	cópia bit a bit d 1,0; `es_env.py`
7× `prb_percentage`	6, 18, 30, 42, 54, 66, 78	afim exata (÷139×100; |dif| = 1,5×10
1× `bs_on`	84	soma exata do (máx |dif| = 1,

Fechamento numérico (2 datasets reais, 4.158 linhas)

$\text{rank}(X_{85}) = \text{rank}(X_{78}) = \text{rank}(X_{70}) = 70$ (tol 10^{-8}); condição $\approx 5{,}3\times10^{20}$ (base) e $4{,}9\times10^{20}$ (d1d3). O compacto-78 "herdado" ainda carregava **8 colinearidades exatas**; o **compact70 tem posto completo**.

Ganho para IQL/CQL (≈3.400–4.000 transições)

	85 dims	**70 dims**
N/d (N = 4.000)	47,1	**57,1**
N/d (N = 3.400)	40,0	**48,6**
pesos 1ª camada (512)	43.520	**35.840**

+21% de transições por dimensão *sem coletar nada novo*; −17,6% de pesos; fim dos mínimos quadrados mal-postos nos regressores de valor. Eq. (2) intacta (usa totais brutos de `raw_kpms`, não o estado).

`STATE_VARIANTS["compact70"]` · `config.py:90-133` · `kpm_audit.md`

Matriz Experimental de Estado da Arte (Tabela III) & Posicionamento

Grupo	Política / agente	ΔE	ΔThr	RLF	Status
Baselines reais	Always-On	0,0%	0,0%	máx 18	medido 5/5
	Static (3,2,2)	+12,1%	−20,0%	máx 20	medido 5/5
	Dynamic (3,2,2)	+12,2%	−23,9%	máx 22	medido 5/5
	Random	+21,4%	−61,7%	máx 48	medido 5/5
Artigo base (publicado)	PPO-2	+24,2%	−52,3%	máx 2 (relatado)	valores do texto
	DQN (REM+CQL)	+1,3%	−9,6%	máx 1 (relatado)	valores do texto
E2: sem restrição	BC (replay ponderado)	—	—	—	[TARGET EXP: IQL/CMDP]
	CQL (REM-DQN)	—	—	—	[TARGET EXP: IQL/CMDP]
	IQL puro (D4)	—	—	—	[TARGET EXP: IQL/CMDP]
E1: nosso	**IQL/CQL + CMDP Lagr.**	$\geq 10\%$	$\geq -10\%$	≤ 2	[TARGET EXP: IQL/CMDP]
	IQL + porta de SLA (5.1′)	$\geq 10\%$	$\geq -10\%$	≤ 2	[TARGET EXP: IQL/CMDP]

Por que *um* artigo unificado (Diagnóstico + Solução)

O diagnóstico isolado é um *negative result* de workshop; a solução isolada perde a motivação. Juntos: um **benchmark QoS-aware completo** — auditoria D1–D4 + reward hacking quantificado + Pareto com piso de SLA + CMDP/offline RL + compact70 + protocolo de 5 seeds — com impacto direto para **IEEE TNSM / TWC** ou conferência *flagship*; nenhum dos 27 trabalhos da nossa matriz faz restrição de QoS no treino com os 85 KPMs e avaliação live em ns-3.

Cronograma de Fechamento & Próximos 4 Comandos

1. **Rerun cirúrgico dos 6 jobs pendentes** → **40/40** (≈9 h de máquina; mortes em 1,1–9,9 s ⇒ custo real 8–90 min/run; patch IHL ativo; `gdb -batch` nos 3 casos de SACK antes de qualquer segundo patch).

   `scripts/run_paper_baselines.py --only <jobs 5,6,18,26,38,39> --force`

2. **Tabelas atualizadas** 21 → 40/40 + **dataset final em** `compact70` (e `compact70+gate` ⇒ 71 dims), com calibração quantílica *antes* da conversão.

   `analysis/recompute_baselines.py · collect_real_dataset.py --state-variant compact70 · fit_reward_calibration.py`

3. **Treino da grade IQL/CQL** $\lambda \in \{0; 0{,}5; 1; 2; 5; 10\}$, $\lambda_{\max} = 10$ (rápido: offline em CPU/GPU) + seleção dos melhores pontos para avaliação *live* em **5 seeds**.

   `examples/ppo_2.py --dataset <40runs>.npz --offline-algo iql × grade λ`

4. **Fig. 3 definitiva (Pareto com o agente) e congelamento do manuscrito IEEEtran** — alvo quantitativo pré-registrado: $\Delta E \in [10, 20]\%$ com $\Delta\text{Thr} \geq -10\%$ e RLF ≤ 2, IC95 sobre 5 seeds.

   `pareto_build.py · docs/plano_tecnico/ · PITCH_ORIENTADOR_RESULTADOS.md §4.3`

Gate de qualidade já verde: 87 testes · build ns-3 exit 0 · Pareto conferido de forma independente (0,00 pp de desvio) · 100% dados reais, zero `--synthetic`.